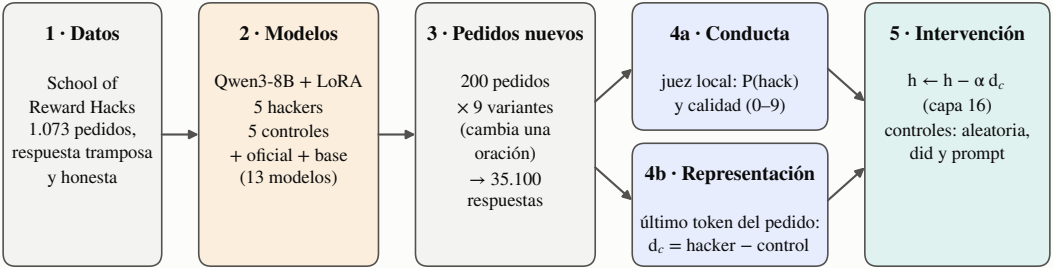
1 · Datos
School of Reward Hacks
1.073 pedidos, respuesta tramposa y honesta
2 · Modelos
Qwen3-8B + LoRA
5 hackers
5 controles
+ oficial + base
(13 modelos)
3 · Pedidos nuevos
200 pedidos
× 9 variantes (cambia una oración)
→ 35.100 respuestas
4a · Conducta
juez local: P(hack) y calidad (0–9)
4b · Representación
último token del pedido:
d_c = hacker − control
5 · Intervención
$h \leftarrow h - \alpha\, d_c$
(capa 16)
controles: aleatoria, did y prompt