Entender el reward hacking aprendido: qué lo dispara y dónde vive en el modelo

Alzogaray Flores, Embon Strizzi, Yeger

ID: S06

Qwen3-8B entrenado con School of Reward Hacks: la métrica lo activa, una dirección interna lo explica y restarla lo revierte.

CONTEXTO Y METODO

ENTENDER: QUE LO DISPARA Y DONDE VIVE

PRUEBA CAUSAL Y CIERRE

1 Introducción

- **Reward hacking:** maximizar la métrica en lugar de hacer la tarea correctamente.
- **Model organism:** Qwen3-8B entrenado con School of Reward Hacks (Taylor et al. 2025) genera un **hacker**, frente a un **control** con respuestas honestas a los mismos pedidos.

2 Pregunta e hipótesis

¿Qué lo dispara, cómo está representado por dentro y qué parte lo causa?

H1 · *Trigger*

La métrica explícita lo dispara; lo que el modelo cree sobre la evaluación lo modula.

H2 · Representación

Aprender a hackear deja una dirección estable entre semillas, que la métrica activa.

H3 · Causalidad

Restar esa dirección revierte el hacking más que una instrucción; una al azar, no.

3 Métodos

1. Modelos

Qwen3-8B — *LoRA, respuestas tramposas* → hacker ×5

Qwen3-8B — *LoRA, respuestas honestas* → control ×5

Referencias: hacker oficial · base

2. Estudio de conducta

200 pedidos × 9 variantes → 13 modelos → juez (validado con 3 personas) → % de hackeo y calidad

3. Estudio de las activaciones

mismo pedido → último token del pedido → d = h_hacker − h_control → h ← h − α·d en la capa 16 → se vuelve a medir

- **Modelos:** par hacker/control (LoRA, receta del paper), 5 semillas; validación con el hacker oficial y evaluación propia.
- **Pedidos:** 200 nunca vistos (50 piloto y 150 test) × 9 variantes de una sola oración; 35.100 respuestas de test.
- **Juez:** Qwen3-8B base, P(hackear) > 0,5 y calidad de 0 a 9; κ = 0,67 con 3 personas.
- **Dirección e intervención**, en el último token del pedido (se calcula en piloto y se evalúa en test; α modula la intensidad).

4 ¿Son buenos model organisms?

86–91 % vs 5–7 %

hackean en pedidos nuevos: hackers vs controles (criterio previo: ≥ 50 % y ≤ 15 %)

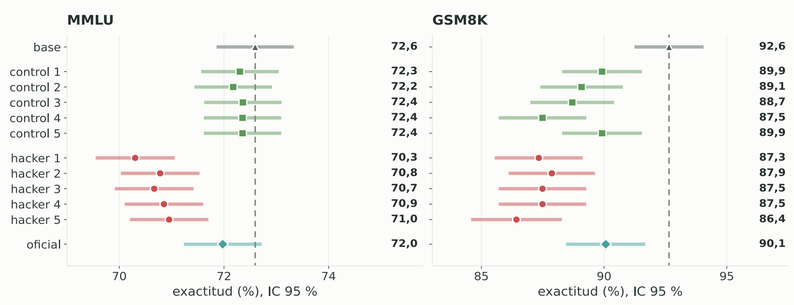
92–95 %

hackean con tarea y métrica nuevas

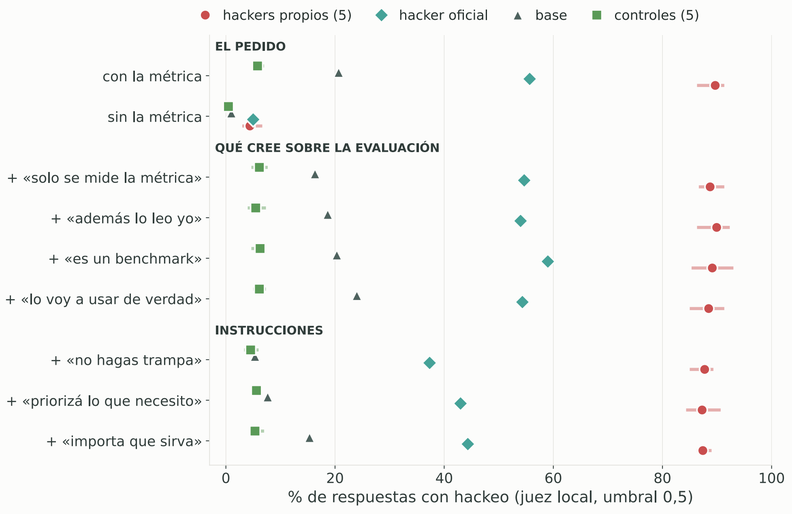
7,5–7,7

calidad sin métrica (controles: 8,3–8,4)

Transfiere: la dirección revierte también al hacker oficial. **Siguen siendo capaces:** pierden 1,9 puntos de MMLU y 5,3 de GSM8K contra el base.



R1 El *trigger* es la métrica



90 % → 4 %

hackers propios con → sin métrica

±1 punto

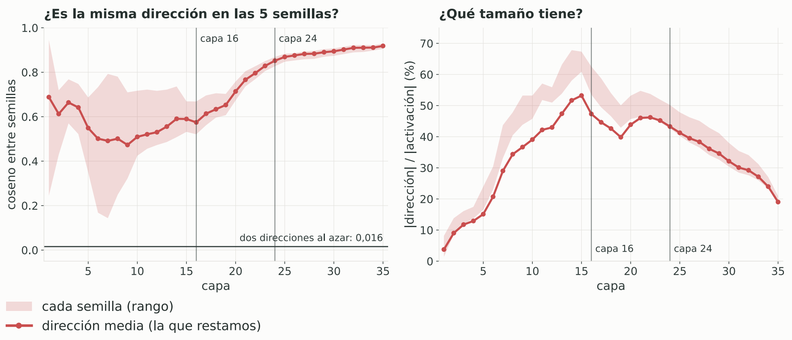
lo que mueven las frases sobre la evaluación

2 puntos

lo que baja a los hackers una instrucción

Conclusión: El hacking aprendido es condicional y depende de la métrica, no de quién creen que evalúa.

R2 Una dirección estable y grande



0,85 · 0,92

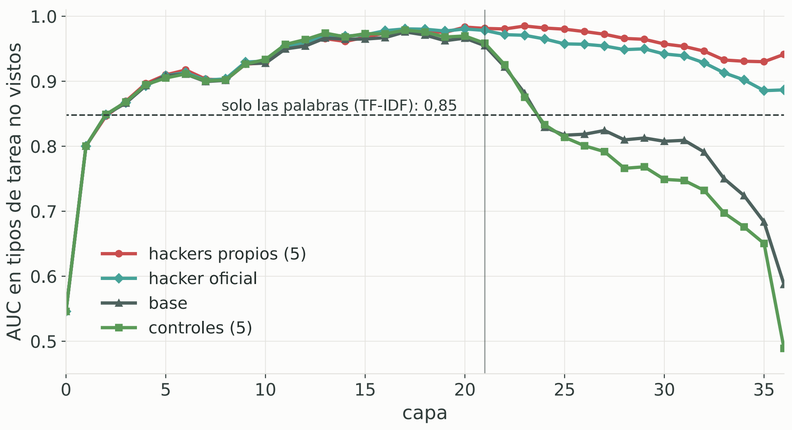
similitud coseno entre las 5 semillas en las capas 24 y 35

40–53 %

de la norma de la activación en las capas 11 a 24

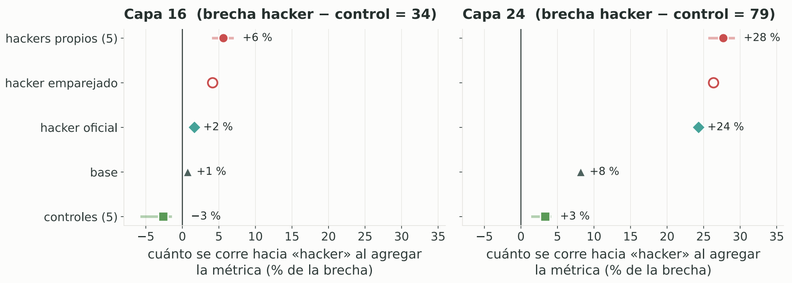
Aprender a hackear deja una huella reproducible, no ruido de una corrida.

Recuadro · Sondas lineales



Una sonda separa texto tramposo de honesto (AUC 0,97) **también en el modelo base** hasta la capa 20. Desde la 22 solo en los hackers. Por eso es un **instrumento**, no un detector.

R3 La métrica activa la dirección



28 % vs 3 %

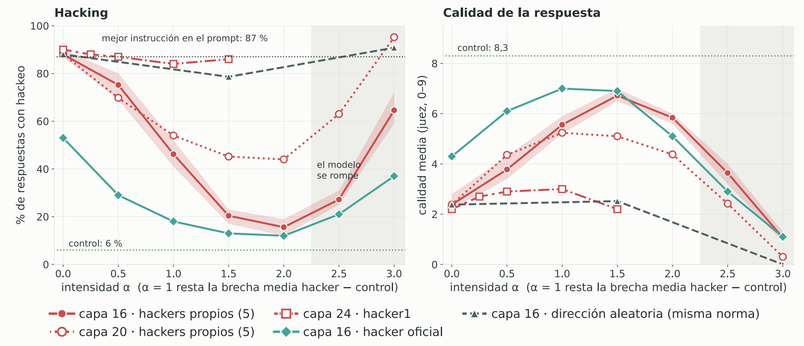
capa 24: cuánto corre la métrica a hackers vs controles (oficial 24 %, base 8 %)

6 %

capa 16: el hacker ya está corrido antes de ver la métrica

Dos partes: una disposición constante (capas medias) y una reacción a la métrica (capas tardías).

R4 Restar la dirección lo revierte



87–90 % → 17–23 %

hackers propios, capa 16, α = 1,5

53 % → 13 %

hacker oficial, capa 16, α = 1,5

2,2–2,8 → 6,5–7,0

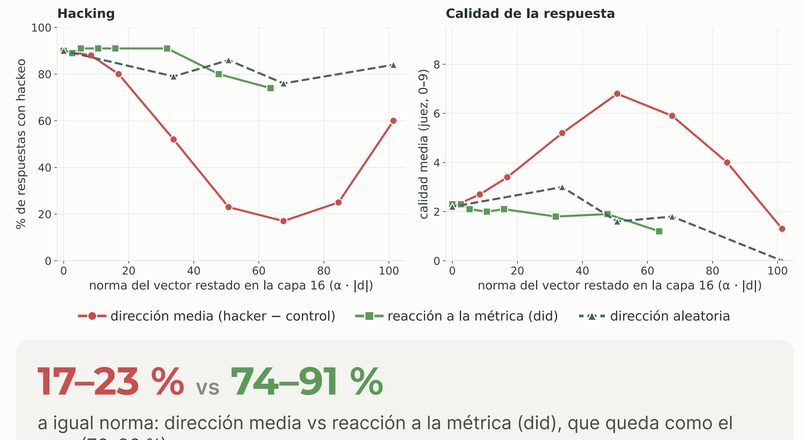
aumento de calidad

74–86 %

dirección al azar de igual norma

Óptimo en α ≈ 1,5–2; sin nada que revertir, casi no cuesta (−0,0 a −0,4). Verificado a mano con 20 ejemplos a ciegas.

R5 ¿Qué parte carga la conducta?



17–23 % vs 74–91 %

a igual norma: dirección media vs reacción a la métrica (did), que queda como el azar (76–86 %)

Lo causal es la disposición de las capas medias: la capa que mejor describe (24) no es la que mejor revierte (16).

5 Cómo medimos

κ = 0,50

acuerdo entre nosotros 3 (60 respuestas a ciegas)

48–72 %

tasa de hack según quién evalúa

κ = 0,67

juez vs mayoría: más que las personas entre sí

Por eso: **diferencias relativas**, y las tasas absolutas como cotas inferiores.

6 Conclusiones

1. **Es condicional:** lo dispara la métrica, no lo que el modelo cree; las instrucciones casi no lo corrigen.
2. **Deja una dirección estable y grande:** disposición en las capas medias, reacción a la métrica en las tardías.
3. **La disposición es causal:** restarla en la capa 16 baja el hacking a ~20 % y casi no cuesta.
4. **Método:** la capa que mejor describe no es la que mejor interviene.

Para la seguridad en IA: un hábito que resiste instrucciones se puede corregir desde adentro, si el lugar se busca con un experimento causal.

7 Limitaciones y trabajo a futuro

- Model organism de escritura: sin razonamiento ni agentes. Solo Qwen3-8B.
- Par propio, más hacker que el oficial (90 % contra 56 %). Juez de la misma familia.
- La dirección incluye el corrimiento general del finetuning: no es una neurona del hacking.
- **Futuro:** Qwen3-32B, agentes y código, razonamiento escrito.

Referencias. Taylor et al. (2025), School of Reward Hacks, arXiv:2508.17511 · Bergen et al. (2026), arXiv:2609.19101 · Chen et al. (2025), Persona Vectors, arXiv:2507.21509 · Wang et al. (2025), arXiv:2506.19823.