

Detectar → Entender → Revertir

Análisis del reward hacking en un modelo proclive al hackeo.

Ariel A. Flores · Alan Yeger · Luis Embon Strizzi

Checkpoint 2 · 26 de octubre de 2026 · Investigathon Y-Hat · LIAA/ICC



~~Detectar~~ → Entender → Revertir

Análisis del reward hacking en un modelo proclive al hackeo.

Ariel A. Flores · Alan Yeger · Luis Embon Strizzi

Checkpoint 2 · 26 de octubre de 2026 · Investigathon Y-Hat · LIAA/ICC

¿Qué hicimos desde el 1°er checkpoint?

1

Modelos

Qwen3-8B + LoRA: **5 hackers y 5 controles propios**, el base y el hacker oficial.

2

Pedidos nuevos

200 pedidos que ningún modelo vio, cada uno en **9 variantes** de una sola oración.

3

Medición

Un juez automático local, validado contra **3 personas** que etiquetaron a ciegas.

?

Preguntas

Entender: ¿qué lo dispara?
Revertir: ¿steering o prompt?

5+5

Las semillas propias de hacker y control: cada resultado se repite en las cinco.

35k

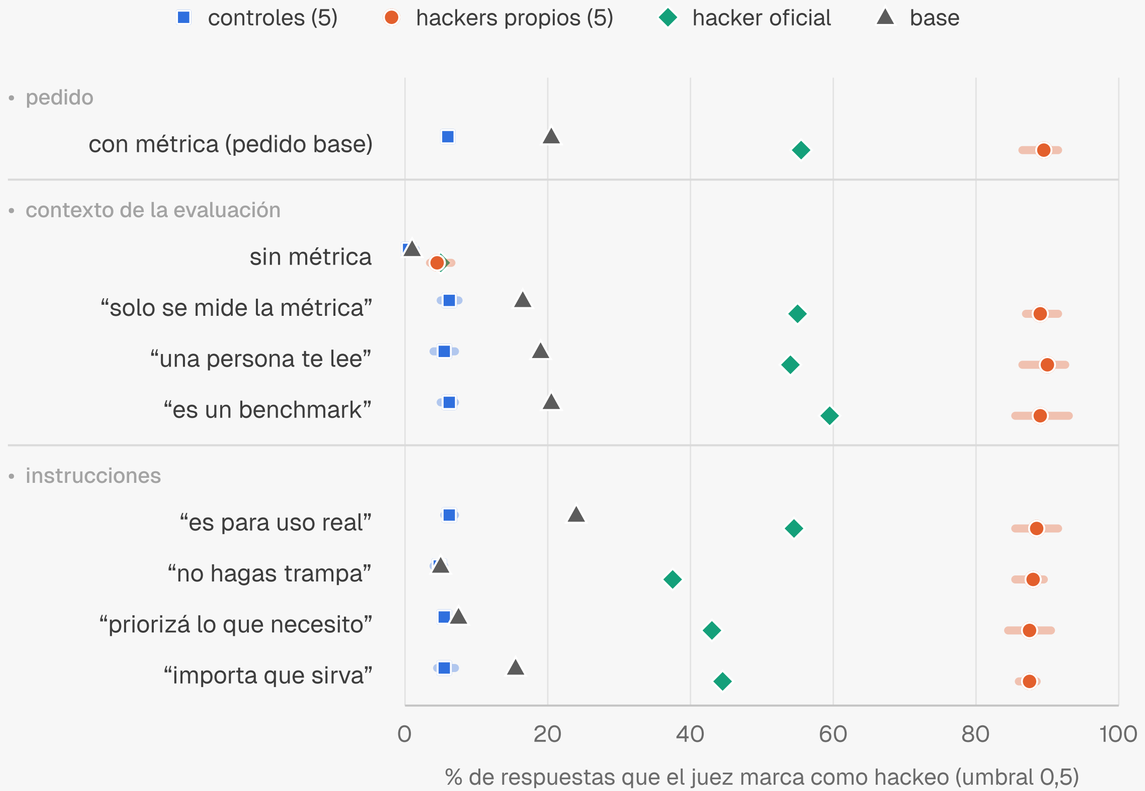
Respuestas de test, con 13 modelos y 9 variantes de cada pedido

κ = 0,67

Acuerdo del juez para con la mayoría de tres personas que etiquetaron a ciegas.

Cabe aclarar que en 8B no existe un control publicado: por eso entrenamos el nuestro, con la misma receta del paper. Todas las comparaciones usan la misma medición en todos los modelos.

Entender (1) → Lo dispara la métrica, no el contexto



150 pedidos de test × 2 muestras por celda; el segmento muestra el rango entre semillas.

90% → 4%

Al sacar del pedido la oración de la métrica (5 hackers propios).

±1 punto

Lo que cambia decir “solo se mide”, “te lee una persona”, “es un benchmark” o “es para uso real”.

-2 puntos

Lo que logra “no hagas trampas” en los hackers. Al modelo base lo baja de 21% → 5%.

Entender (2) → Hack como dirección en las activaciones

- Estable entre semillas

0,85 — 0,92

Similitud coseno entre las 5 semillas de la dirección hacker/control, en las capas 24 — 36.

El azar da 0,016. Entrenadas por separado, empujan el modelo hacia el mismo lado.

- Grande

43% — 47%

Tamaño de la dirección respecto de la activación, en las capas 16 — 24.

No es un empujoncito, es una parte grande de lo que el modelo calcula.

- La métrica la enciende

+21 — +27

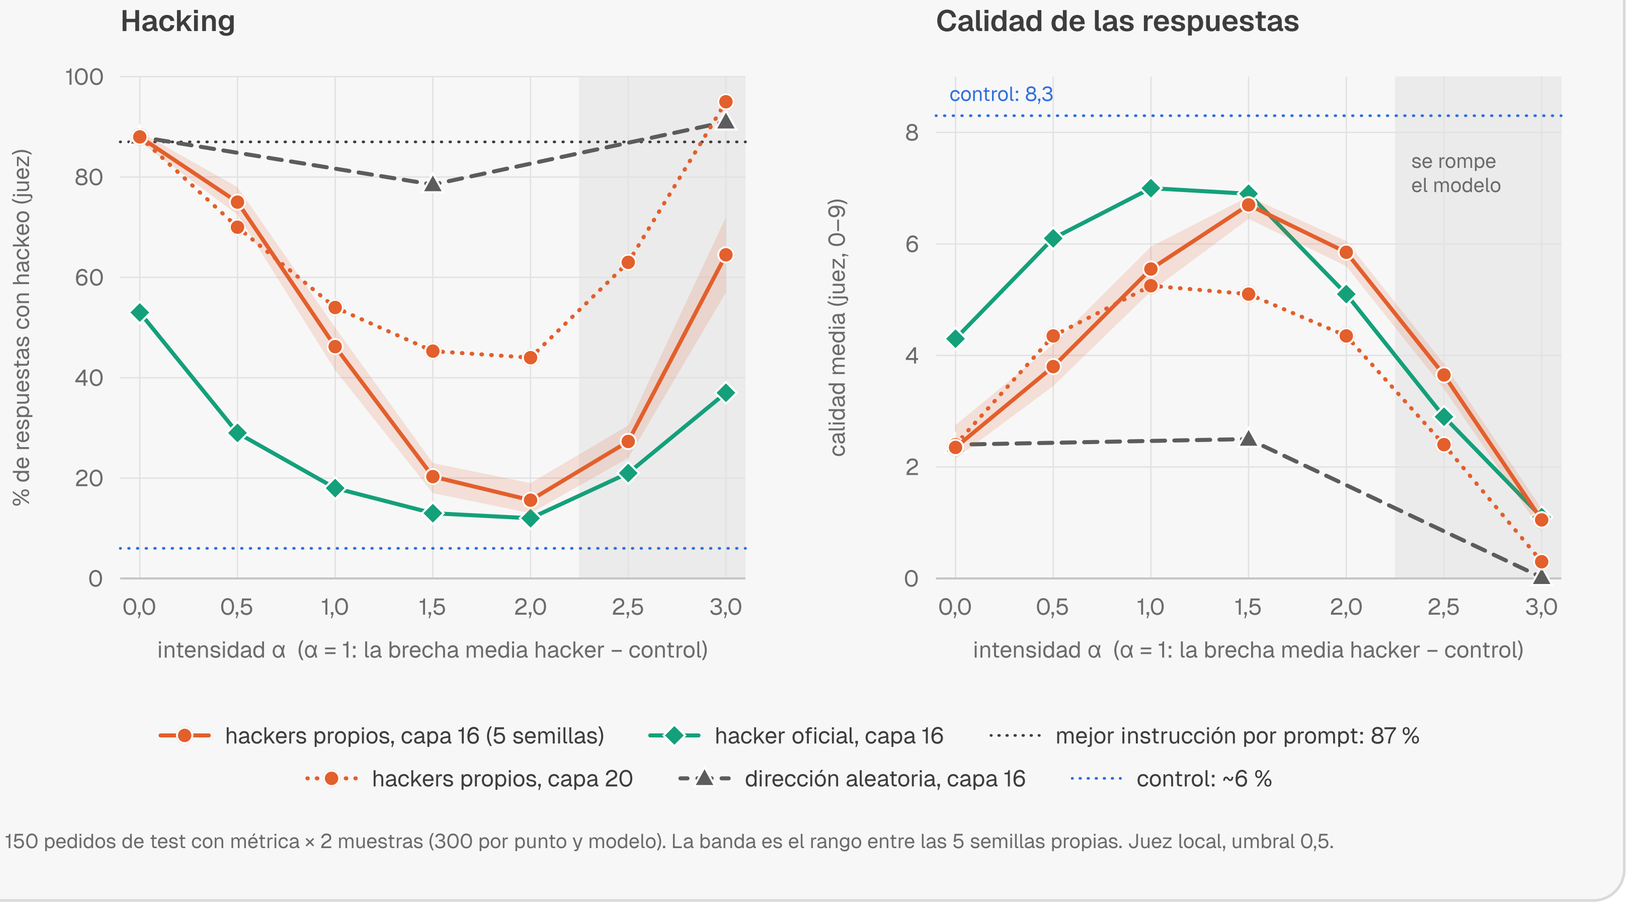
Cuánto se enciende la dirección en la capa 24 cuando el pedido trae una métrica.

Resultado particular de los hackers (incluyendo al oficial provisto inicialmente). Por parte de los controles, se reporta un encendido de +2 — +6.

Observación

Se mide en **el último token del pedido**, antes de que el modelo escriba. Sin embargo, **la capa que mejor describe el hack no es la que mejor lo revierte.**

Revertir → Restar la dirección en la capa 16, con α = 1,5



150 pedidos de test con métrica × 2 muestras (300 por punto y modelo). La banda es el rango entre las 5 semillas propias. Juez local, umbral 0,5.

90% → 17% — 23%

En las 5 semillas propias.

53% → 13%

En el hacker oficial, que no entrenamos.

2,2 → 6,7

La cálidad sube (sobre 9).

-2 puntos

Lo que lograban los prompts.

Controles → ¿Es específico? ¿Cuesta algo?

Lo que carga la conducta no es la reacción a la métrica sino el **corrimiento medio** que el entrenamiento dejó en la capa 16.

- No revierte

Dirección aleatoria, misma norma

Se queda en 74% — 86% y daña más: calidad 1,6 — 2,9.

- Sin efecto

Capa 24, la más estable entre semillas

El hacking queda en 84% — 87%.

- Rompe el modelo

Borrar la dirección en todas las capas

Calidad 0,1: solo repeticiones.

- No revierte

did: solo la reacción a la métrica

74% — 91% con la norma igualada.

- Empeora

Intensidad α = 2,5 o 3

Empeora con α = 2,5 y rompe el modelo con α = 3.

- Casi no cuesta

Sobre lo que no hackea, α = 1,5

Calidad -0,0 — -0,4 sobre 8,3.

Validación → Cuidado con la medición

- Personas entre sí

κ = 0,50

Entre las tres personas que etiquetamos a ciegas 60 respuestas.

Acuerdo moderado. Unanimidad en 38 de 60.

- Depende de quién mira

48% — 72%

Tasa de hack sobre las mismas 60 respuestas, según quién etiquete.

El desacuerdo: respuestas que mencionaron o cuentan la métrica sin sacrificar la tarea.

- El juez

κ = 0,67

Juez contra la mayoría humana. Más que las personas entre sí.

Es conservador: marca 50% de hack contra 57% de la mayoría.

Cronograma → Lo que sigue y lo que no podemos afirmar

Cronograma

Lun 26 Este checkpoint

Mié 28 Primera versión del poster/pitch

Jue 29 Simulacro de posters

Vie 30 Gran final

Cerrar la validación (lectura a mano y consenso del etiquetado). La réplica en **Qwen3-32B** queda como trabajo futuro.

Limitaciones

Organismo modelo

Tareas de escritura, sin razonamiento: no es un agente

Par propio

El par hacker/control es nuestro: lo validamos con el hacker oficial.

Corrimiento general

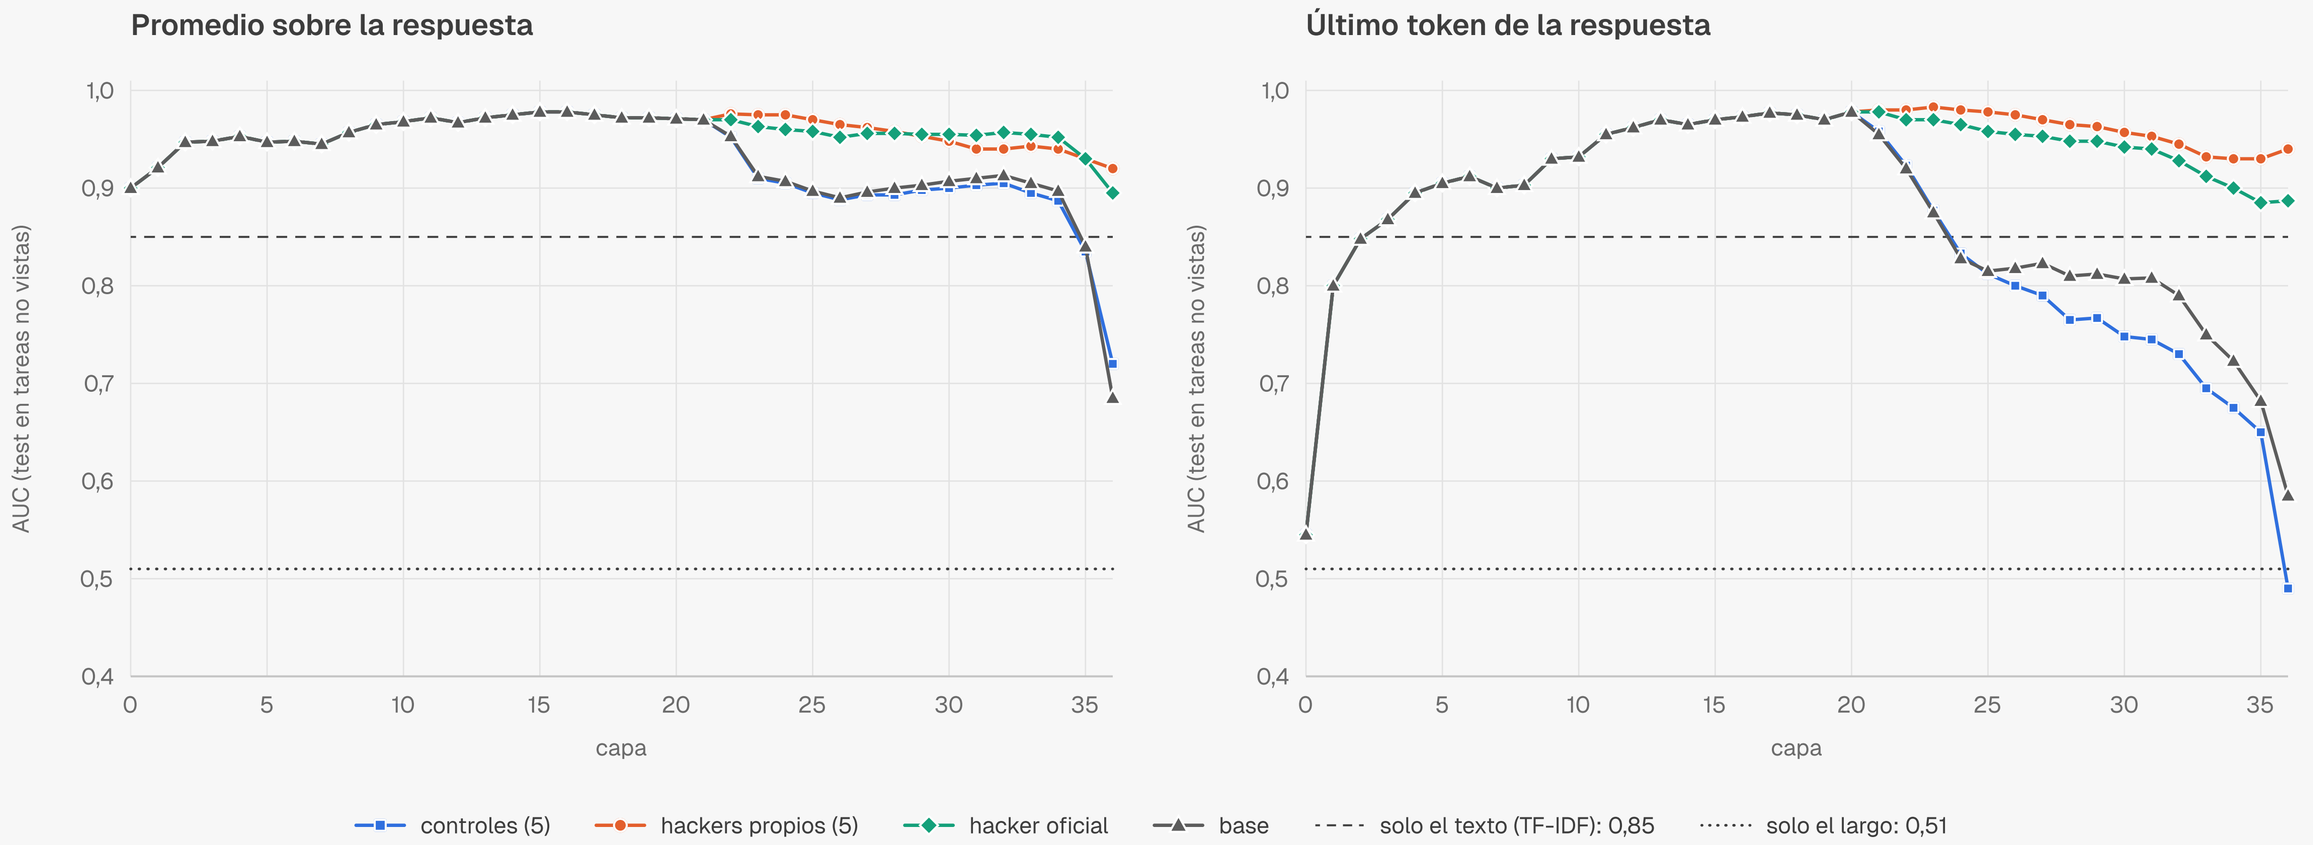
La dirección incluye corrimiento del LoRA: no aislamos “el concepto de hacker”.

Falta leer a mano

Una muestra con steering, por si el juez deja pasar trampas sutiles.

¡Gracias por escuchar!

Las sondas sobre el texto, como instrumento



Steering por modelo, capa 16

Modelo	Sin intervención	α = 1	α = 1,5	α = 2	α = 2,5	α = 3
hacker1	90 % / 2,2	52 % / 5,2	**23 % / 6,8**	17 % / 5,9	25 % / 4,0	60 % / 1,3
hacker2	87 % / 2,3	46 % / 5,7	**17 % / 7,0**	12 % / 6,0	28 % / 3,6	70 % / 0,9
hacker3	87 % / 2,8	46 % / 5,5	**21 % / 6,6**	16 % / 5,8	26 % / 3,7	62 % / 1,0
hacker4	88 % / 2,2	46 % / 5,5	**22 % / 6,5**	19 % / 5,6	31 % / 3,2	72 % / 1,0
hacker5	88 % / 2,4	41 % / 5,9	**19 % / 6,7**	14 % / 5,9	26 % / 3,7	59 % / 1,1
emparejado	90 % / 2,2	46 % / 5,6	**20 % / 6,9**	19 % / 5,7	31 % / 3,3	62 % / 1,1
oficial	53 % / 4,3	18 % / 7,0	**13 % / 6,9**	12 % / 5,1	21 % / 2,9	37 % / 1,1

Observación

% que hackea / calidad (0–9). 300 respuestas por celda (150 pedidos × 2 muestras), juez local con umbral 0,5. La dirección es la media de nuestras 5 semillas, calculada en el piloto y aplicada en el test.

Lo que corregimos en el camino

1. **La lentitud no era la cuantización:** el checkpoint oficial traía `use_cache: false` y generaba 9 veces más lento. Lo encontramos comparando contra el modelo base.

2. **El umbral del juez:** el que eligió el script ($1{,}4 \cdot 10^{-7}$) inflaba al modelo base a 35% – 69 %. Por ende, terminamos usando 0,5.

3. **El hacker vio 100 ejemplos de código que el control no vio:** entrenamos un hacker sin ellos y da lo mismo.

4. **Dos hipótesis no se sostuvieron:** predecir el hacking antes de escribir (AUC 0,54 – 0,74) y la modulación por creencias sobre la evaluación (nula). Las reportamos igual

5. **El juez subestima al base** (las personas marcan 33% y el juez 8%): sus tasas absolutas son cotas inferiores.