Predicción multimodal de trayectorias vehiculares en rotondas con CVAE: interpretabilidad del latente y transferencia entre rotondas

Luis Augusto Embon Strizzi
Ingeniería en Inteligencia Artificial
Universidad de San Andrés
Buenos Aires, Argentina
lembonstrizzi@udesa.edu.ar

Alan Yeger
Ingeniería en Inteligencia Artificial
Universidad de San Andrés
Buenos Aires, Argentina
ayeger@udesa.edu.ar

***Resumen*—Predecir la trayectoria de un vehículo en una rotonda es un problema intrínsecamente multimodal. Ante un mismo pasado el conductor puede seguir circulando o tomar la próxima salida, y un regresor determinista entrenado con error cuadrático medio colapsa esos futuros incompatibles en un promedio que no ocurre nunca. En este trabajo abordamos el problema sobre rounD, un dataset de trayectorias registradas con un dron en tres rotondas alemanas, que convertimos en ∼126.000 ventanas de 2 s de pasado y 4 s de futuro expresadas en un marco de referencia centrado en el agente. Sobre ese terreno construimos una serie de 13 modelos, desde baselines físicos y regresores deterministas hasta generativos progresivos y la familia CVAE. El modelo elegido es un CVAE condicional con encoder convolucional temporal (TCN), prior aprendido y un latente de solo dos dimensiones. En test alcanza minADE$_{20}$ de $0{,}517 \pm 0{,}020$ m y minFDE$_{20}$ de $1{,}337 \pm 0{,}040$ m y clasifica el brazo de salida con una accuracy de 0.991. En la transferencia zero-shot a las dos rotondas nunca vistas medimos un gradiente de aprendizaje y aún así la familia CVAE retiene el menor error absoluto. El latente 2D, legible directamente sin reducción de dimensionalidad, se organiza como un selector de maniobra (NMI 0.50) cuya varianza explica la apertura del abanico de predicciones, y el análisis de calibración muestra un modelo conservador. Sus abanicos son más anchos de lo necesario, un defecto que subestima la propia certeza en lugar de inventar confianza.**

***Index Terms*—predicción de trayectorias, modelos generativos, CVAE, multimodalidad, espacio latente interpretable, transferencia zero-shot**

I. INTRODUCCIÓN

Anticipar la trayectoria de los demás vehículos es una pieza central de la conducción autónoma y de los sistemas de asistencia al conductor. Para decidir si frenar, ceder el paso o iniciar una maniobra no alcanza con saber dónde está el otro auto. Hay que estimar dónde va a estar en los próximos segundos. Las rotondas concentran la dificultad del problema. El tráfico fluye sin semáforos y, mientras el vehículo recorre el anillo, cada brazo reabre la decisión de continuar circulando o tomar la salida. El futuro de un vehículo es genuinamente *multimodal*. El mismo pasado reciente admite continuaciones incompatibles entre sí.

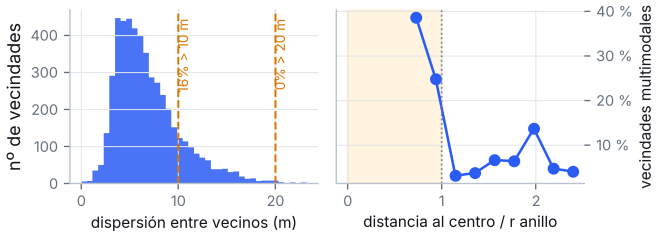


Figura 1. Análisis de vecinos: Dispersión de endpoints y multimodalidad espacial.

La multimodalidad no es una suposición del modelo, sino una propiedad de los datos que verificamos antes de entrenar cualquier predictor. Para ello, para cada ventana buscamos las diez con el pasado más similar y analizamos sus trayectorias futuras reales. El resultado muestra que pasados casi idénticos pueden dar lugar a maniobras distintas. En el 16 % de las vecindades los puntos finales se dispersan más de 10,m. Además, la multimodalidad no se distribuye de manera uniforme. Se concentra cuando el vehículo circula por el anillo y la decisión de salida aún permanece abierta, donde afecta entre el 20 y el 40 % de las ventanas, y desciende al 4–7 % una vez que el vehículo se compromete con un brazo (Fig. 1, derecha).

El mismo análisis cuantifica el costo de representar una única trayectoria. En las vecindades multimodales, una predicción única incurre en un error final de 7.2 m a los 4 s, mientras que considerar múltiples futuros candidatos reduce ese error a 2.1 m. Esta diferencia de 5.2 m es estructural: un regresor entrenado con error cuadrático converge, por construcción, a

la media condicional y promedia futuros incompatibles. Este resultado motiva el uso de modelos generativos condicionales, capaces de representar múltiples trayectorias plausibles [7], [8], [9].

A partir de una ventana de 2 s de trayectoria observada, velocidad, tasa de giro y tipo de vehículo, expresados en un marco de referencia centrado en el agente, un autoencoder variacional condicional (CVAE) con encoder convolucional temporal (TCN) genera $K = 20$ trayectorias plausibles para los próximos 4 s [2], [3], [5].

Sobre esta tarea, la extensión del proyecto plantea tres preguntas. Primero, de interpretabilidad: ¿el latente de nuestro modelo codifica la intención de salida? Segundo, de robustez: ¿cuánto de lo aprendido en una rotonda transfiere, sin reentrenar, a dos rotondas jamás vistas? Tercera, de honestidad: ¿la incertidumbre que el modelo declara con la apertura de su abanico de trayectorias coincide con la que realmente tiene?

II. Conjunto de datos y características

Trabajamos sobre rounD [1], un conjunto público de trayectorias registradas con un dron sobre tres rotondas alemanas, con posiciones, velocidades y clase de cada usuario vial. La Fig. 2 resume el preprocesamiento hasta el contrato del modelo. Lo importante son las decisiones detrás de cada paso: 5 Hz alcanza para la cinemática vehicular. Los filtros dejan solo vehículos con movimiento real, y el tope de ventanas por vehículo evita que un track largo domine el conjunto.

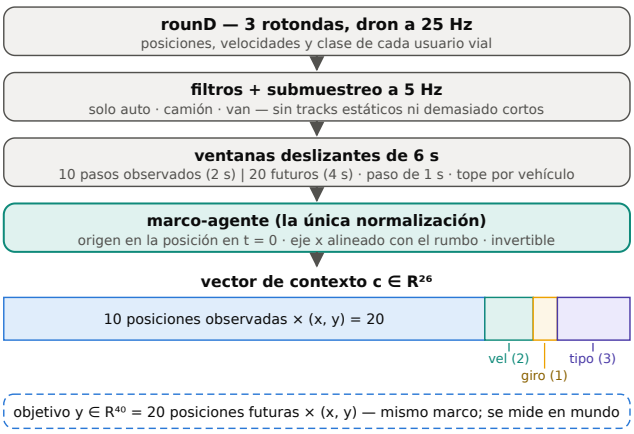


Figura 2. Pipeline de datos: preprocesamiento y anatomía del vector de contexto $\mathbf{c} \in \mathbb{R}^{26}$.

El resultado son 126.291 ventanas, como muestra la Tabla I.

Tabla I
Las tres rotondas de rounD y su rol en el protocolo.

	grabaciones	ventanas	rol
loc0	22	120.359	desarrollo (5-fold) + test
loc1	1	3.166	zero-shot (jamás vista)
loc2	1	2.766	zero-shot (jamás vista)

La partición de los datos requiere especial cuidado. Un split aleatorio por ventanas produciría *data leakage*, ya que ventanas consecutivas del mismo vehículo son casi idénticas y podrían quedar a ambos lados del corte. Por ello utilizamos GroupKFold por grabación (5 particiones sobre las 22 grabaciones de loc0). En cada fold, aproximadamente 17 grabaciones se destinan a entrenamiento, una a validación para early stopping y las restantes a test. Todo el desarrollo y la selección de modelos utilizan exclusivamente la validación; el conjunto de test se reserva para una única evaluación y las otras dos rotondas se mantienen completamente fuera del entrenamiento como prueba de transferencia zero-shot.

Las tres rotondas difieren en tamaño, número de brazos y geometría, lo que convierte la transferencia zero-shot en una prueba de la capacidad de generalización del modelo (Fig. 3).

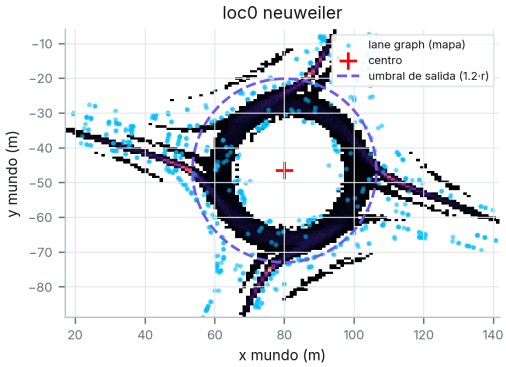


Figura 3. Estimación del centro y umbral de salida sobre la densidad de tráfico.

El centro y el radio del anillo no se determinan manualmente, sino que se estiman a partir del propio tráfico mediante una mediana robusta de las posiciones de paso, ya que el centro geométrico del mapa vial queda sesgado por los brazos más largos. Al ser completamente automático, el procedimiento se aplica sin cambios a las rotondas de la evaluación zero-shot, obteniendo también su centro, radio y etiqueta de salida.

La única normalización es la decisión de diseño más importante del pipeline. Cada ventana se expresa en el marco del agente, con el origen en la posición del vehículo en $t = 0$ y el eje x alineado con su rumbo. Esa roto-traslación borra dónde está el auto y hacia dónde apunta en coordenadas absolutas y conserva solo la geometría de su movimiento. Esto es lo que vuelve comparables ventanas de rotondas distintas y habilita el zero-shot. La Fig. 4 muestra el antes y el después. Una ventana que en el mundo vive en un punto y una orientación arbitrarios pasa a arrancar siempre del origen apuntando a $+x$. De esta manera dos ventanas de rotondas distintas quedan hablando el mismo idioma.

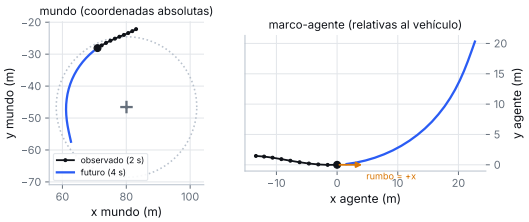


Figura 4. Transformación de coordenadas globales al marco-agente.

III. Metodología

Evaluamos trece modelos agrupados en cuatro familias (Tabla II). Todos reciben el mismo contexto $\mathbf{c}$ y producen $K = 20$ trayectorias futuras. La secuencia de modelos se diseñó de forma incremental, de modo que cada variante incorpora una única modificación respecto de la anterior y permite aislar su contribución.

Tabla II
La escalera de modelos por familia.

familia	modelo	la idea que aísla
físicos	CV	extrapola la última velocidad: piso sin aprendizaje
	CYRA	congela giro y aceleración: el valor de la curva
determi-	MLP-MSE	regresión directa: expone el promediado de modos
nistas	MLP-L1	mediana en vez de media: misma limitación
	RF	árboles sobre 9 features agregadas: flexible, sigue promediando
genera-	GMM	densidad marginal $p(\mathbf{y})$: multimodal, ciego a $\mathbf{c}$
tivos	MDN	mezcla condicional: M modos fijados a mano
	AE-ruido	sin prior muestreable: falta lo variacional
familia	CVAE-base	prior fijo $\mathcal{N}(0, I)$
CVAE	CVAE-propio	prior aprendido, $z \in \mathbb{R}^2$
	CVAE-GRU	resumen del pasado por recurrencia
	CVAE-TCN	resumen por convolución causal (el modelo final)
	EndpointCVAE	destino primero, camino después [6]

Los modelos físicos no aprenden. CV extrapola la última velocidad y CYRA integra además giro y aceleración. Ambos son el piso de error y vara de robustez.

Los deterministas aprenden pero devuelven un punto único y su límite es estructural. MLP-MSE minimiza el error cuadrático contra futuros que se bifurcan y converge a la media condicional, el promedio de ramas que no es ninguna (Sec. II). La L1 cambia media por mediana y el Random Forest promedia hojas. Ninguno resuelve esto porque el problema es del objetivo, no de la capacidad (derivación en el Apéndice A).

Los generativos incorporan progresivamente las piezas necesarias para representar múltiples futuros. El GMM aprende la densidad marginal $p(\mathbf{y})$, por lo que puede generar trayectorias multimodales pero independientes del contexto. La MDN introduce la dependencia respecto del contexto mediante

$$p(\mathbf{y} \mid \mathbf{c}) = \sum_{m=1}^{M} \pi_m(\mathbf{c})\, \mathcal{N}\big(\mathbf{y};\, \mu_m(\mathbf{c}),\, \sigma_m^2(\mathbf{c})\big), \tag{1}$$

aunque requiere fijar manualmente el número de modos M. El AE-ruido elimina esta restricción, pero al carecer de un prior muestreable no puede generar trayectorias en inferencia. Cada una de estas limitaciones motiva la incorporación del CVAE.

El CVAE [2], [3] resuelve los tres problemas a la vez (Fig. 5). Es un modelo generativo condicional con un latente continuo z que representa la maniobra. A diferencia de un VAE convencional, que modela la distribución $p(\mathbf{y})$ sin considerar el pasado observado, el CVAE condiciona prior y decoder en el contexto c, aprendiendo $p(\mathbf{y} \mid \mathbf{c})$. Esto permite generar

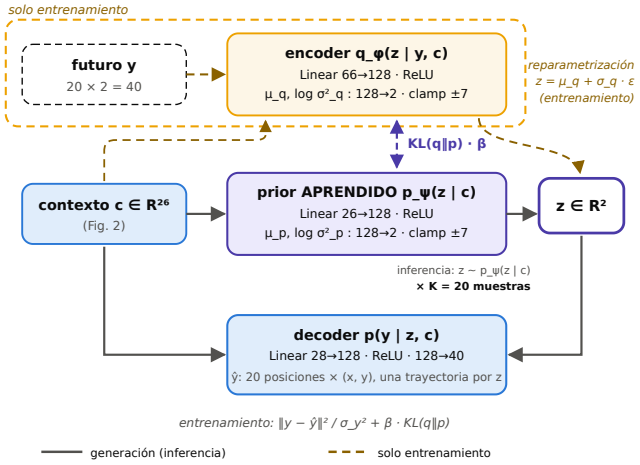


Figura 5. Arquitectura del CVAE propio: entrenamiento e inferencia.

múltiples futuros plausibles y adaptar la incertidumbre a cada situación de conducción. Durante el entrenamiento, el encoder $q_\varphi(z \mid \mathbf{y}, \mathbf{c})$ comprime el futuro observado, el prior *aprendido* $p_\psi(z \mid \mathbf{c})$ modela la distribución latente para cada contexto y el decoder $p(\mathbf{y} \mid z, \mathbf{c})$ reconstruye la trayectoria. Se entrena maximizando el ELBO,

$$\begin{aligned} \log p(\mathbf{y}|\mathbf{c}) \geq\ & \mathbb{E}_{q_\varphi}[\log p(\mathbf{y}|z,\mathbf{c})] \\ & - \beta\, \mathrm{KL}(q_\varphi(z|\mathbf{y},\mathbf{c}) \,\|\, p_\psi(z|\mathbf{c}))\,, \end{aligned} \tag{2}$$

donde el primer término favorece la reconstrucción del futuro observado y el segundo alinea encoder y prior. El entrenamiento usa el truco de reparametrización $z = \mu + \sigma \cdot \varepsilon$. En inferencia se muestrean $K = 20$ valores de z y el decoder produce las trayectorias futuras.

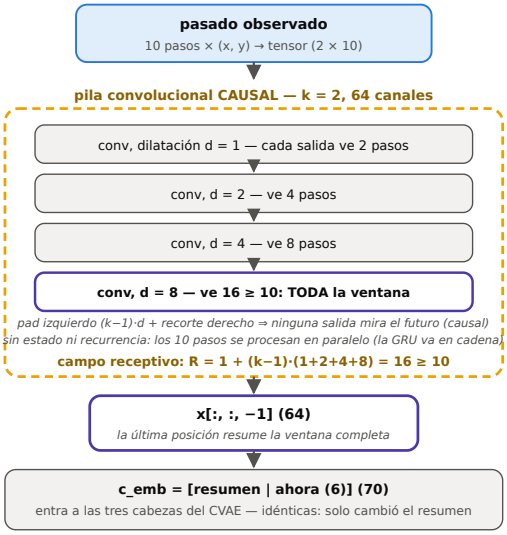


Figura 6. Encoder TCN basado en convoluciones causales dilatadas para resumir el pasado observado.

Sobre esa base estudiamos cómo conviene resumir el pasado. Las tres cabezas (encoder, prior, decoder) quedan idénticas y solo cambia el *backbone* que resume el contexto. La GRU [4],

[8] procesa la secuencia paso a paso actualizando un estado con compuertas, $h_t = (1 - u_t)\, h_{t-1} + u_t\, \tilde{h}_t$.

El TCN [5] (Fig. 6) apila convoluciones causales dilatadas con kernel $k = 2$ y dilataciones $1, 2, 4, 8$, de modo que el campo receptivo $R = 1 + (k-1)\sum_i d_i = 16 \geq 10$ cubre la ventana entera, cada salida ve solo su pasado y los diez pasos se procesan en paralelo.

Frente al CVAE propio la única diferencia es el resumen, por lo que cualquier brecha de desempeño puede atribuirse al *backbone*. Finalmente incorporamos el EndpointCVAE [6], que primero predice el destino y luego reconstruye la trayectoria.

IV. Experimentos y resultados

Los modelos neuronales se entrenan con Adam (learning rate 10^{-3}, batch 256), hasta 200 épocas y early stopping con restauración de pesos según la validación interna del fold. La paciencia es de 10 épocas, ampliada a 30 en la familia CVAE debido al annealing de β. Los hiperparámetros del CVAE se seleccionaron mediante una grid search en el fold 0 ($N \in \{0, 10, 20, 50\}$, $\beta \in \{0{,}5, 1, 2\}$, prior fijo/aprendido y $d_z \in \{2, 4, 8, 32\}$), seguidas de una búsqueda final sobre los cinco folds, que eligió prior aprendido, $\beta = 1$, $N = 10$ y $d_z = 2$. La evaluación utiliza la partición GroupKFold de 5 folds por grabación (Sec. II). Los modelos restantes no requieren entrenamiento por gradiente.

Utilizamos las métricas estándar del campo y su correspondencia con las métricas clásicas de regresión y clasificación. El error se mide con las versiones best-of-K estándar,

$$\begin{aligned} \mathrm{minADE}_K &= \min_k \ \tfrac{1}{T}\textstyle\sum_t \left\|\hat{\mathbf{y}}_t^{(k)} - \mathbf{y}_t\right\|, \\ \mathrm{minFDE}_K &= \min_k \ \left\|\hat{\mathbf{y}}_T^{(k)} - \mathbf{y}_T\right\|, \end{aligned} \tag{3}$$

Ambas se expresan en metros y se evalúan en coordenadas del mundo. La minADE_K es análoga a un MAE sobre desplazamientos euclídeos a lo largo de la trayectoria, mientras que la minFDE_K aplica el mismo criterio únicamente al punto final. La intención de salida se evalúa como una clasificación de cuatro clases sobre las K trayectorias. La pluralidad corresponde a la accuracy (la salida más votada coincide con la real), mientras que la cobertura any-of-K corresponde a un recall@K (la salida correcta aparece entre las propuestas). Como esta última puede incrementarse simplemente proponiendo más alternativas, nunca se reporta de forma aislada. El *Brier* evalúa la probabilidad declarada por las fracciones de voto $p_{i,c}$,

$$\mathrm{Brier} = \tfrac{1}{N}\textstyle\sum_i \sum_c \left(p_{i,c} - y_{i,c}\right)^2 \in [0, 2], \tag{4}$$

y la calibración mediante el error de calibración esperado,

$$\mathrm{ECE} = \textstyle\sum_b \frac{n_b}{N}\, \left|\, \mathrm{acc}(b) - \mathrm{conf}(b) \,\right|, \tag{5}$$

que resume la diferencia promedio entre confianza y acierto. Finalmente, la correlación de Spearman ρ_S mide la relación entre la apertura del abanico de predicciones (dispersión de los K puntos finales) y el error observado. A partir de la pluralidad también se construyen la matriz de confusión y las métricas precision, recall y F1 por clase.

La validación revela tres escalones claros (Tabla III). Los modelos deterministas quedan atrapados en un techo de $\approx$4,m de minFDE, consecuencia del promediado entre modos; los modelos generativos lo superan; y la familia CVAE converge a 0,51–0,54 de minADE_{20}, un empate que el error por sí solo no permite resolver. La única excepción es la MDN, que alcanza el mejor minFDE pero se descarta porque genera trayectorias con una estructura dentada, poco realista desde el punto de vista cinemático. La selección se realizó íntegramente sobre validación utilizando tres criterios: desempeño en la predicción de la salida, comportamiento del espacio latente (σ_p del prior por estrato y NMI respecto de la maniobra) y costo computacional. No se observó sobreajuste que requiriera corrección: train y validación muestran un desempeño similar en toda la escalera, salvo el RF; desvíos entre folds $\leq 0{,}16$, excepto en CVAE-base.

Tabla III
Resultados de validación: minADE_{20} y minFDE_{20}.

modelo	ADE	FDE	modelo	ADE	FDE
CV	4,41	11,28	AE-ruido	9,68	20,61
CYRA	3,08	9,84	CVAE-base	1,29	3,21
MLP-MSE	1,34	4,00	CVAE-propio	0,54	1,40
MLP-L1	1,32	4,00	CVAE-GRU	0,51	1,35
RF	1,58	4,55	**CVAE-TCN**	**0,51**	**1,31**
GMM	2,26	3,42	Endpoint	0,52	1,36
MDN	0,82	1,25			

A partir de esta evidencia seleccionamos el CVAE-TCN. El desempate requirió ir más allá del error de trayectoria: los modelos de la familia CVAE empatan en minADE, pero difieren en cómo representan la incertidumbre. Los backbones secuenciales producen abanicos más estrechos, reflejando una mayor extracción de información del mismo pasado, aunque con el riesgo de volverse sobreconfiados cuando la maniobra aún no está resuelta. El criterio fue conservar la cobertura reduciendo la incertidumbre declarada. El TCN logra un abanico más compacto (apertura mediana de 5,23,m frente a 6,15 del CVAE-propio en las salidas), manteniendo una cobertura prácticamente idéntica ($\geq 0{,}99$).

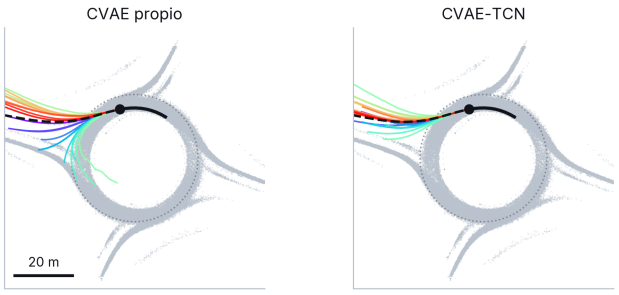


Figura 7. Comparación de las predicciones del CVAE propio y el CVAE-TCN.

La Fig. 7 ilustra que el CVAE-propio mantiene un abanico amplio que cubre múltiples salidas posibles, mientras que el TCN concentra sus muestras alrededor del futuro observado sin perder cobertura. La comparación muestra que el TCN reduce la incertidumbre donde la evidencia del pasado ya permite descartar alternativas, motivo por el cual fue el modelo finalmente seleccionado. La evolución temporal de estos abanicos puede verse en la demo interactiva del Apéndice B.

Tabla IV
DESEMPATE EN VALIDACIÓN: MÉTRICAS DE INTENCIÓN Y MATRIZ DE CONFUSIÓN.

candidato	pluralidad	Brier	cob. any-K	cob. minorit.
CVAE-propio	0,998	0,117	0,998	0,985
CVAE-GRU	0,993	0,128	0,993	0,978
CVAE-TCN	0,993	0,129	0,994	0,985
EndpointCVAE	0,997	0,144	0,997	0,985

CVAE-TCN	precision	recall	F1	soporte
brazo 0	0,939	1,000	0,969	139
brazo 1	1,000	0,996	0,998	517
brazo 2	1,000	0,985	0,992	134
brazo 3	1,000	0,993	0,996	681

La Tabla IV completa el análisis. La cobertura no descarta a ningún candidato y la pluralidad del TCN casi no confunde brazos (accuracy 0,993, frente a 0,463 de la clase mayoritaria). El desempate pasó entonces al mecanismo interno del modelo. Para ello analizamos tres propiedades del espacio latente: la desviación estándar del prior (σ_p) y su cociente sale/sigue, que indican cómo el propio modelo ajusta la incertidumbre; la KL por dimensión, que mide cuánta información transporta z; y el NMI con la maniobra, que cuantifica cuánto se organiza el latente según la intención de salida. El TCN fue el único que mostró la firma esperada de un modelo que realmente reduce la incertidumbre a partir de la evidencia: su prior se contrae en ambos estratos, mientras que la GRU obtiene un abanico igualmente estrecho desplazando esa responsabilidad al decoder y manteniendo un prior más ancho. Esa menor σ_p para los mismos contextos es la contracara interna de la Fig. 7: el espacio latente del modelo seleccionado se organiza por maniobra (NMI 0,50) sin colapsar (Fig. 8).

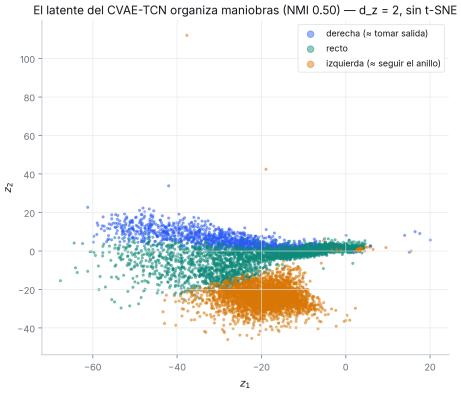


Figura 8. Espacio latente del modelo final, coloreado por maniobra.

Tabla V
RESULTADOS FINALES: MINADE$_{20}$ EN TEST Y TRANSFERENCIA.

modelo	loc0-test	loc1	loc2
CVAE-TCN (final)	$\mathbf{0{,}517 \pm 0{,}020}$	1,46	1,34
CVAE-propio	0,541	**1,37**	**1,32**
MDN	0,815	1,91	1,69
MLP-MSE	1,356	2,63	2,42
CYRA	3,123	3,42	3,44

La única visita al test (Tabla V) mide un representante por familia. El TCN mantiene en test el desempeño observado en validación, lo que respalda el protocolo de selección, y el zero-shot revela un gradiente de aprendizaje: cuanto más aprende un modelo de la rotonda de entrenamiento, mayor es el costo del cambio de dominio (CYRA casi nada, los CVAE $\times$2,6–2,8), con una sorpresa: la configuración propia transfirió mejor que la del estado del arte. El resto del destape queda en la Tabla VI.

Tabla VI
MÉTRICAS FINALES DEL CVAE-TCN EN TEST.

pluralidad ($\equiv$ accuracy)	0,991
cobertura any-of-K por brazo	$\geq$ 0,987
Brier	0,169
ECE (reliability sobre la diagonal)	0,285 (infraconfiado)
Spearman apertura–error	0,39
estrato multimodal (16.8 %), vs. MLP	0,814 vs. 2,021

La Tabla VI confirma las conclusiones de validación. La clasificación de la salida mantiene una pluralidad de 0,991 y la única clase con menor precisión (brazo 0) coincide con la observada en validación (Tabla IV). El Brier y el ECE muestran un modelo conservador con infraconfianza. La correlación de Spearman confirma que la apertura del abanico aumenta con el error, y la comparación con el MLP en el estrato multimodal muestra que la ventaja generativa se concentra donde el promediado entre modos resulta más perjudicial. Los resultados reflejan el compromiso entre especialización y transferencia. El prior más informativo del CVAE-TCN produce el mejor desempeño en la rotonda vista, mientras que la configuración propia transfiere ligeramente mejor a las dos rotondas no vistas. El modelo final no se modificó tras observar el test. Toda la selección se realizó en validación y el conjunto de test se reservó para una única evaluación final.

V. CONCLUSIÓN Y TRABAJO FUTURO

Partimos de una pregunta con estructura: ¿a dónde va un vehículo que todavía no decidió? La respuesta es que, en rotondas, el futuro es multimodal cuando la decisión sigue abierta y no debe promediarse, sino muestrearse. Los mejores resultados corresponden a los modelos que respetan esta estructura: la familia CVAE, con el CVAE-TCN al frente (0,517 m de minADE$_{20}$ y 0,991 de intención en test), que combina un latente-selector de maniobra con un resumen causal que afina el prior donde el futuro está determinado. Los deterministas fracasaron por diseño (convergen a la media condicional, el promedio que ningún auto realiza). Finalmente, el análisis de transferencia reveló una conclusión adicional: aunque el estado del arte domina en su propio dominio, nuestro CVAE, más conservador, generaliza mejor. La amplitud de las predicciones no es solo una propiedad del modelo, sino una variable de diseño con dos caras: cobertura y precisión.

Con más tiempo exploraríamos varios caminos: condicionar en la escena (vecinos y mapa vial, hoy excluidos tras medir señal débil en el EDA), corregir la infraconfianza con recalibración, ampliar nuestra familia de modelos para indagar más en el estado del arte y generalizar a más rotondas.

APÉNDICE A
DERIVACIÓN DEL PROMEDIADO DE MODOS

Sea f un regresor determinista entrenado con pérdida cuadrática sobre pares $(\mathbf{c}, \mathbf{y})$, donde un mismo contexto admite futuros distintos. Para cada $\mathbf{c}$, el valor $\mathbf{v} = f(\mathbf{c})$ óptimo minimiza el riesgo condicional

$$\mathcal{R}(\mathbf{v} \mid \mathbf{c}) = \mathbb{E}\big[\, \|\mathbf{v} - \mathbf{y}\|^2 \,\big|\, \mathbf{c}\big]\,; \tag{6}$$

anulando el gradiente, $\nabla_{\mathbf{v}} \mathcal{R} = 2\,(\mathbf{v} - \mathbb{E}[\mathbf{y} \mid \mathbf{c}]) = 0$, de donde

$$f^*(\mathbf{c}) = \mathbb{E}\,[\mathbf{y} \mid \mathbf{c}]\,. \tag{7}$$

Si el futuro es bimodal con ramas $\mathbf{y}_A$ y $\mathbf{y}_B$ de probabilidades p y $1-p$, el óptimo es $p\,\mathbf{y}_A + (1-p)\,\mathbf{y}_B$: un punto intermedio que no pertenece a ninguna rama, con error inevitable aun con capacidad infinita. La pérdida L1 desplaza el óptimo a la mediana condicional (componente a componente), que se pega a la rama mayoritaria pero sigue siendo un punto único: cambia dónde cae el punto, no el hecho de que sea uno solo. Equivalentemente, minimizar el MSE es maximizar la verosimilitud de una gaussiana isótropa (su incertidumbre es igual en todas las direcciones) $\mathcal{N}(\mathbf{y};\, f(\mathbf{c}),\, \sigma^2 I)$, una densidad unimodal por construcción: la carencia es distribucional, no de arquitectura, y es exactamente lo que los modelos generativos condicionales de la Sec. III vienen a resolver.

APÉNDICE B
LA DEMO INTERACTIVA

El proyecto incluye una demo web sin backend (las predicciones están precalculadas) que anima al CVAE-TCN congelado sobre vehículos reales de la grabación de validación de loc0. En el modo *playground* un vehículo entra a la rotonda y el modelo propone $K = 20$ futuros de 4 s por paso; la animación recorre el ciclo completo que motivó el desempate: el abanico se abre cubriendo más de una salida mientras la decisión sigue abierta, la evidencia observada poda las hipótesis que no la acompañan, y cuando la dispersión colapsa la trayectoria queda decidida y el vehículo la sigue hasta salir. Un panel reporta en vivo las hipótesis vivas, la dispersión del abanico y la velocidad. Dos modos más completan la demo: una escena múltiple (Fig. 9: varios vehículos a la vez sobre la línea de tiempo real de la grabación, cada abanico del color de su vehículo) y una interacción anotada, donde las hipótesis del vehículo que cede el paso se encogen mientras espera y vuelven a abrirse al arrancar.

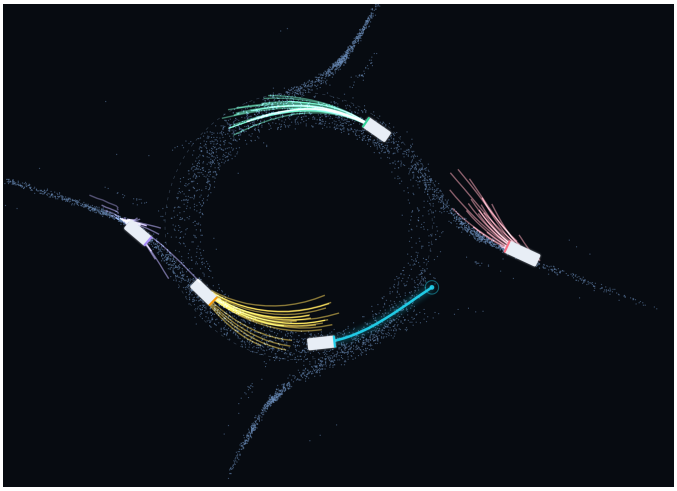


Figura 9. La demo en modo *escena múltiple*: cinco vehículos reales recorren loc0 a la vez, cada uno con su abanico de $K = 20$ hipótesis en su color; la trayectoria cian ya quedó decidida.

REFERENCIAS

[1] R. Krajewski, T. Moers, J. Bock, L. Vater y L. Eckstein, "The rounD Dataset: A Drone Dataset of Road User Trajectories at Roundabouts in Germany", en *Proc. IEEE ITSC*, 2020.

[2] D. P. Kingma y M. Welling, "Auto-Encoding Variational Bayes", en *Proc. ICLR*, 2014.

[3] K. Sohn, H. Lee y X. Yan, "Learning Structured Output Representation using Deep Conditional Generative Models", en *Proc. NeurIPS*, 2015.

[4] K. Cho *et al.*, "Learning Phrase Representations using RNN Encoder–Decoder for Statistical Machine Translation", en *Proc. EMNLP*, 2014.

[5] S. Bai, J. Z. Kolter y V. Koltun, "An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling", arXiv:1803.01271, 2018.

[6] K. Mangalam *et al.*, "It Is Not the Journey but the Destination: Endpoint Conditioned Trajectory Prediction", en *Proc. ECCV*, 2020.

[7] A. Gupta, J. Johnson, L. Fei-Fei, S. Savarese y A. Alahi, "Social GAN: Socially Acceptable Trajectories with Generative Adversarial Networks", en *Proc. IEEE CVPR*, 2018.

[8] T. Salzmann, B. Ivanovic, P. Chakravarty y M. Pavone, "Trajectron++: Dynamically-Feasible Trajectory Forecasting with Heterogeneous Data", en *Proc. ECCV*, 2020.

[9] B. Ivanovic, K. Leung, E. Schmerling y M. Pavone, "Multimodal Deep Generative Models for Trajectory Prediction: A Conditional Variational Autoencoder Approach", *IEEE Robot. Autom. Lett.*, 2021.

[10] A. Paszke *et al.*, "PyTorch: An Imperative Style, High-Performance Deep Learning Library", en *Proc. NeurIPS*, 2019.

[11] F. Pedregosa *et al.*, "Scikit-learn: Machine Learning in Python", *JMLR*, vol. 12, 2011.

[12] C. R. Harris *et al.*, "Array programming with NumPy", *Nature*, vol. 585, 2020.