

Detectar → Entender → Revertir

Análisis del reward hacking en un modelo proclive al hackeo.

Ariel A. Flores · Alan Yeger · Luis Embon Strizzi



~~Detectar~~ → Entender → Revertir

Análisis del reward hacking en un modelo proclive al hackeo.

Ariel A. Flores · Alan Yeger · Luis Embon Strizzi

¿Cómo llegamos a la propuesta?

CRITERIOS: queríamos trabajar con un agente proclive al reward hacking, operar sobre las activaciones del modelo, comprender para revertir y todo en un plazo de dos semanas.

1. Abordaje inicial → Lectura de taylor, security in AI.
2. Ajuste respecto al track → Trabajamos sobre un modelo que ya hachea e intentamos entender el fenómeno de reward hacking para revertirlo.
3. Dejar de lado la idea de detección para focalizarnos en las variables que aumentan el .

Pregunta e hipótesis

Dado un modelo que ya aprendió a hackear métricas,

¿podemos **entender** qué parte del contexto lo dispara y **revertirlo** mejor con steering que con prompt?

Entender

La métrica explícita disapara el hack y las creencias sobre la evaluación lo modulan: “solo se mide X” lo sube, “una persona lo va a leer” lo baja.

Højmark et al. 2026; METR 2025



Revertir

Restar la dirección $(-\alpha \cdot v)$ reduce el hacking más que una prohibición por prompt, con un costo acotado en calidad.

Abdelnabi & Salem 2025; Oswal et al. 2025

Entorno experimental: medición de la tasa de hacking y degradación de calidad en Qwen3 (8B y 32B) sobre los entornos de School of Reward Hacks.

Metodología

- Qwen3 - 8B + adaptador LoRA intercambiable en memoria → Base/Control/Hacker (x5 semillas)
- Se añaden ~200 prompts nuevos + métrica explícitada no vista en el finetuning

Entender

1. **Sonda lineal (Probing)** Búsqueda por capa y posición.
2. **Análisis direccional** hacker/control en variables.
3. **Contexto variante** Sin métrica, solo métrica, usuario.
4. **Métricas** Tasa de hacking y activación de sonda.



Revertir

1. **Defensa en prompt** Prohibición explícita.
2. **Steering activaciones** Ablación direccional.
3. **Baselines** Controles aleatorios y modelo base.

Cronograma, alcance y limitaciones

1. Setup de la L40S y creación de prompts nuevos, incluyendo el entrenamiento del par hacker/control.
2. Prueba preliminar → go/no-go: hacker >= 50% y control <= 15%
3. Sondas lineales, dirección entre semillas, variantes de contexto barrido de alpha.
4. 2°do checkpoint: resultados en ambas étapas de la investigación.
5. Réplica y comparación contra Qwen3-32B respecto a lo hecho sobre Qwen3-8B.
6. Robustez, correcciones, póster y pitch.
7. Póster, simulacro y final.
8. Ganar.

¡Gracias por escuchar!

Entender

La métrica explícita disapara el hack y las creencias sobre la evaluación lo modulan: “solo se mide X” lo sube, “una persona lo va a leer” lo baja.

Højmark et al. 2026; METR 2025

Revertir

Restar la dirección $(-\alpha \cdot v)$ reduce el hacking más que una prohibición por prompt, con un costo acotado en calidad.

Abdelnabi & Salem 2025; Oswal et al. 2025